

BMW Car Sales Classification

Predmetni projekat — SAUSAU 2026

Klasifikacija prodajnog uspeha BMW automobila

Stefan Selić

Jun 2026.

1. Opis problema

Tema ovog projekta je predviđanje prodajnog uspeha BMW automobila. Konkretno, na osnovu različitih karakteristika vozila treba da se odredi da li će prodaja biti visoka (klasa High) ili niska (klasa Low). Radi se o binarnoj klasifikaciji.

Skup podataka sadrži 50 000 zapisa sa 11 atributa. Ciljna promenljiva je Sales_Classification, a kao prediktori se koriste: model vozila, godište, region prodaje, boja, vrsta goriva, tip menjača, zapremina motora, kilometraža i cena.

Jedna stvar koja mi je odmah zapala za oko jeste kolona Sales_Volume — ona direktno određuje ciljnu klasu (High ako je Sales_Volume ≥ 7000 , inače Low). To je klasičan data leakage problem i o tome kako sam ga rešio piše u sekciji o preprocesiranju.

2. Opis skupa podataka

Skup podataka sadrži sledeće attribute:

- Model — BMW model (5 Series, X3, i8, M5 ...)
- Year — godište vozila
- Region — region prodaje (Asia, Europe, North America, ...)
- Color — boja vozila
- Fuel_Type — vrsta goriva (Petrol, Diesel, Electric, Hybrid)
- Transmission — tip menjača (Manual / Automatic)
- Engine_Size_L — zapremina motora u litrima
- Mileage_KM — kilometraža
- Price_USD — cena u USD
- Sales_Volume — ostvareni obim prodaje
- Sales_Classification — ciljna promenljiva: High / Low

Nije bilo nedostajućih vrednosti ni duplikata. Raspodela klasa nije ravnomerna: 69.5% Low nasuprot 30.5% High, što je trebalo uzeti u obzir pri izboru metrike.

3. Preprocesiranje podataka

3.1 Nedostajuće vrednosti i duplikati

Prva stvar koju sam proverio su nedostajuće vrednosti. U celom skupu ih nema — svih 50 000 redova je kompletno popunjeno. Duplikata takođe nema. Ipak, kod je pripremljen da ih obradi ako se pojave: numeričke kolone bi se popunile medijanom, a kategorijske modom.

3.2 Detekcija anomalija

Primenio sam dve standardne metode za detekciju anomalija:

- IQR metoda ($1.5 \times$ međukvartilni raspon) — pronašla 0 anomalija
- Z-score metoda ($|z| > 3$) — takođe 0 anomalija

U ranijoj verziji koda sam probao i domensku logiku — izbacivanje redova sa nerealnom kilometražom po godini vožnje ($> 50\,000$ km/god ili < 100 km/god). Međutim, odlučio sam to da izbacim iz finalnog rešenja.


3.3 Obrada kolone Sales_Volume

Ovo je bio najinteresantniji deo preprocesiranja. Sales_Volume direktno određuje Sales_Classification: vrednosti ≥ 7000 su klasa High, a ispod 7000 su Low. To znači da model koji koristi tu kolonu može postići 100% tačnosti — ali samo zato što mu je u suštini 'prokazana' ciljna promenljiva. Ovo je data leakage.

Razmatrao sam dve opcije: potpuno izbacivanje ili smanjivanje njenog uticaja. Odlučio sam se za drugu opciju i primenio dvostruku transformaciju:

1. Panderisuci faktor $\times 0.1$ — skalira vrednosti na desetinu. Ova transformacija sama po sebi ne pomaže kod stabala jer su ona invarijantna na monotone transformacije (split na 700 je funkcionalno isti kao split na 7000).

2. Gaussov šum (std = 2000) — dodat pre skaliranja. Šum sa standardnom devijacijom od 2000 je dovoljno veliki da prelapa granicu od 7000: vrednost od 6500 (Low) može da dobije šum koji je gurne iznad granice, i obrnuto. Time Sales_Volume postaje slab, ali ne i potpuno beskoristan prediktor.




Slika 1 — Raspodela Sales_Volume po klasama (pre transformacije)

4. Eksplorativna analiza skupa podataka

4.1 Raspodela ciljne promenljive


Kao što sam već napomenuo, klase nisu ravnomerno zastupljene — 69.5% Low i 30.5% High. Razlika od skoro 40 procentnih poena je značajna i direktno je uticala na izbor metrike za poređenje modela: umesto obične accuracy, koristio sam balanced accuracy.



Slika 2 — Raspodela klasa ciljne promenljive

4.2 Korelaciona analiza numeričkih atributa


Ispitao sam korelacije između numeričkih atributa (Year, Engine_Size_L, Mileage_KM, Price_USD i Sales_Volume posle transformacije). Nijedna korelacija nije značajna — sve vrednosti su bliske nuli. To nije iznenađujuće jer su podaci verovatno sintetički generisani nezavisno jedan od drugog, bez realne veze između karakteristika vozila i prodajnih rezultata.




Slika 3 — Korelaciona matrica numeričkih atributa

4.3 Analiza kategorijskih atributa

Za svaki kategorijski atribut (Model, Region, Fuel_Type, Transmission) napravio sam grafikon koji prikazuje udeo klase unutar svake kategorije. Generalno, ni jedan kategorijski atribut ne pokazuje jaku diskriminativnu moć — raspodela High/Low je relativno ujednačena kroz sve kategorije.



Slika 4 — Zastupljenost klase po modelu vozila



Slika 5 — Zastupljenost klasa po regionu prodaje

5. Odabir i treniranje modela

5.1 Podjela podataka i enkodiranje

Podatke sam podijelio na tri skupa:

- Trening skup: 70% (~35 000 redova)
- Validacioni skup: 15% (~7 500 redova)
- Test skup: 15% (~7 500 redova)

Enkodiranje kategorijskih atributa sam radio kroz OneHotEncoder u okviru sklearn Pipeline-a, a numeričke attribute sam normalizovao StandardScaler-om. Ovaj pristup sprečava data leakage pri cross-validaciji jer se fit Scaler-a i Encoder-a radi isključivo na trening podacima.

5.2 Poređenje modela

Testirao sam 6 različitih algoritama. Kao primarnu metriku za poređenje koristio sam CV Balanced Accuracy (5-fold cross-validation), iz dva razloga:

1. CV je pouzdaniji od jednog validacionog skupa jer meri performansu na 5 različitih podjela podataka.
2. Balanced accuracy ispravlja neujednačenost klasa (69.5% vs 30.5%) — obična accuracy bi bila varljiva jer bi model koji uvek predviđa Low već imao 69.5% tačnosti.

Model	Val Accuracy	CV Bal. Acc	CV Std
Random Forest	0.8312	0.8262	0.0010
Gradient Boosting	0.8483	0.8057	0.0024
Logistic Regression	0.8498	0.8046	0.0025
XGBoost	0.8386	0.7977	0.0037
KNN	0.8164	0.7580	0.0047
Decision Tree	0.7690	0.7382	0.0051

5.3 Izbor finalnog modela

Odabrao sam Random Forest kao finalni model. Ima najveći CV Balanced Accuracy (0.8262) i najmanji CV Std od svih (0.0010) — što znači da je i najstabilniji.

Logistic Regression i Gradient Boosting imaju nešto viši Val Accuracy, ali njihov CV score je niži, što ukazuje da su bili malo 'srećni' na tom konkretnom validacionom splitu, a ne generalno bolji.

6. Podešavanje hiperparametara

Za Random Forest sam koristio GridSearchCV sa 5-fold cross-validacijom i `balanced_accuracy` kao metrikom. Pretražio sam sledeće kombinacije parametara:

- `n_estimators`: [100, 200]
- `max_depth`: [None, 10]
- `max_features`: ['sqrt', 'log2']

Ukupno je bilo 8 kombinacija x 5 foldova = 40 fitova. GridSearch je pronašao optimalne vrednosti i taj model je korišćen za finalnu evaluaciju na test skupu.

Parametar `max_depth=None` znači da stabla rastu do potpune dubine (bez ograničenja), što Random Forestu generalno odgovara jer agregacija većeg broja dubokih stabala smanjuje varijansu i sprečava overfitting.

7. Analiza rezultata predikcije

7.1 Korišćene metrike


Za evaluaciju finalnog modela koristio sam sledeće metrike:

- Accuracy — opšta slika tačnosti modela
- Precision — od svih predviđenih High, koliko je zaista High
- Recall — od svih stvarnih High, koliko je model pronašao
- F1-score — harmonijska sredina Precision i Recall
- ROC-AUC — sposobnost modela da razdvoji klase bez obzira na prag

Precision i Recall su posebno važni u poslovnom kontekstu: lažno pozitivni (High predikcija za vozilo koje se zapravo slabo prodaje) znači nepotrebno angažovane resurse, dok lažno negativni (propuštena High prodajna šansa) znači izgubljen prihod.

7.2 Rezultati na test skupu

Finalni model je evaluiran na test skupu koji nije viđen ni tokom treninga ni tokom podešavanja hiperparametara. Postignuta tačnost je ~82-83% na test skupu. Takođe je urađeno 5-fold cross-validation na trening skupu, gde je model pokazao stabilne i konzistentne rezultate (mala standardna devijacija)




Slika 6 — Confusion Matrix na test skupu

8. Odabir najznačajnijih atributa

8.1 Feature Importance

Koristio sam ugrađen Random Forest mehanizam za određivanje važnosti atributa (`feature_importances_`). Ovaj mehanizam prati koliko svaki atribut smanjuje Gini nečistoću prosečno po svim stablima u šumi.

`Sales_Volume` i dalje ima najveći udeo u važnosti, ali je Gaussov šum uspešno smanjio njenu dominaciju u poređenju sa situacijom gde bi ostala netaknuta (gde bi bila ~99.5%). Pored `Sales_Volume`, model i `Region` vozila model koristi kao korisne prediktore.



Slika 7 — Feature Importance — top 15 atributa

8.2 Poređenje: svi atributi vs. top 5

Uporedio sam performansu modela kada koristi sve attribute nasuprot samo top 5 najvažnijih. Model sa svim atributima daje značajno bolju tačnost, što potvrđuje da je korisno zadržati sve dostupne attribute čak i kada neki od njih imaju relativno mali pojedinačni doprinos.

9. Deployment modela

Model je eksportovan pomoću joblib biblioteke u vidu .pkl fajlova:

- model.pkl — istrenirani Random Forest pipeline
- le_target.pkl — enkoder ciljne promenljive
- categories.pkl — kategorije za UI
- data_splits.pkl — sačuvani skupovi za evaluaciju

Deployment je realizovan na dva načina.

9.1 FastAPI REST API

Implementiran je FastAPI servis koji prima podatke o vozilu i vraća predikciju. API ima dva endpoint-a:

- GET / — proverava da li servis radi
- POST /predict — prima JSON sa karakteristikama vozila, vraća klasu (High / Low)

Ulazni podaci su validirani kroz Pydantic model, što garantuje ispravnost tipova pre nego što se proslede modelu. Servis se pokreće sa:

```
uvicorn app.api:app --reload
```

9.2 Streamlit web aplikacija

Za jednostavno korišćenje napravio sam i Streamlit web aplikaciju. Korisnik bira model vozila, region, gorivo, menjač i boju iz padajućih menija, a godište, zapreminu, kilometražu i cenu unosi klizačem ili poljem za unos.

Aplikacija koristi prilagođeni prag (threshold = 0.35) za konačnu predikciju: ako je verovatnoća za klasu High veća od 35%, vozilo se klasifikuje kao High prodaja. Ovaj prag je niži od standardnih 50% upravo zbog neujednačenosti klasa — željeli smo da model bude osetljiviji na High klasu.

Aplikacija se pokreće sa:

```
streamlit run app/ui.py
```

10. Zaključak

U ovom projektu sam prošao kroz sve standardne faze machine learning procesa: preprocesiranje, eksplorativnu analizu, treniranje i poređenje modela, podešavanje hiperparametara, evaluaciju i deployment.

Najveći izazov bio je rad sa Sales_Volume kolonom. Bez ikakve obrade, model bi postigao 100% tačnosti — ali to ne bi imalo nikakvu praktičnu vrednost jer bi u realnom scenariju Sales_Volume bio nepoznat u trenutku predviđanja. Rešenje sa kombinacijom panderisuci faktora i Gaussovog šuma je smanjilo dominaciju te kolone i dalo modelu priliku da uči i iz ostalih atributa.

Kao finalni model odabran je Random Forest, koji je pokazao najveći CV Balanced Accuracy i najmanju varijansu između foldova. Postignuta tačnost od oko 82-83% na test skupu zadovoljava postavljeni cilj od >80%.

Treba napomenuti da bi u realnom scenariju performansa modela (bez Sales_Volume) bila znatno niža jer preostali atributi — cena, kilometraža, model vozila — nemaju stvarnu kauzalnu vezu sa prodajnim uspehom u ovom sintetički generisanom skupu. Za realniji model trebalo bi prikupiti podatke koji zaista odražavaju tržišnu dinamiku (sezonalnost, konkurentske cene, marketinški trendovi, itd.).